

pontia

Máster de Inteligencia Artificial Generativa

Prompt Engineering

Introducción a la Inteligencia Artificial



CONTENIDO

1. Evolución de la IA
2. Modelos clave de IA
3. Casos de uso populares
4. Los parámetros de los LLM

PONTIA





01

Evolución de la IA

- Inicios de la IA (Mediados del siglo XX): Los sistemas basados en reglas eran el enfoque principal. Se usaban reglas predefinidas y árboles de decisión para procesar los datos de entrada y salida.
- Limitaciones de los sistemas basados en reglas: No eran buenos para tareas complejas y dinámicas debido a su rigidez.
- Aparición del aprendizaje automático: Los modelos de aprendizaje automático aprenden patrones de los datos de entrenamiento y los aplican para hacer predicciones. Este enfoque basado en datos permitió a los sistemas de IA abordar tareas más complejas y generalizar mejor a nuevas situaciones.
- IA generativa: El próximo avance en la evolución de la IA. A diferencia de los modelos de aprendizaje automático tradicionales, los modelos generativos generan nuevos datos basados en patrones y distribuciones observados en los datos de entrenamiento.
- Modelos generativos de IA clave:
 - Máquinas restringidas de Boltzmann (RBMs)
 - Autoencoders Variacionales (VAEs)
 - Redes Generativas Antagonistas (GANs)
 - Redes Neuronales Recurrentes (RNNs)
 - Memoria a Largo Plazo de Corta Duración (LSTMs)
 - Transformers



02

Modelos clave de IA generativa

- La IA generativa comprende varios modelos, incluyendo RBMs, VAEs, GANs, RNNs, LSTMs y Transformadores.
- Las RBMs son modelos de aprendizaje no supervisados que aprenden la distribución de probabilidad de los datos de entrada.
- Los VAEs combinan aprendizaje profundo y inferencia bayesiana para aprender distribuciones de datos complejas.
- Las GANs usan dos redes neuronales en competencia para generar datos sintéticos que parecen reales.
- Las RNNs y las LSTMs son útiles para procesar secuencias de datos y pueden manejar tareas que involucran series temporales o datos secuenciales.
- Los Transformadores, como GPT, utilizan mecanismos de auto-atención y pueden procesar secuencias en paralelo, siendo eficientes para tareas a gran escala.

Casos de uso populares de la IA generativa

- Procesamiento de Lenguaje Natural (NLP):
 - Generación de texto coherente y contextualmente relevante
 - Aplicaciones: chatbots, resumen, traducción, generación de contenido
 - Modelos como GPT para generación de texto similar al humano
- Síntesis y Edición de Imágenes:
 - Creación de imágenes realistas desde cero o basadas en atributos específicos
 - Modelos como GANs y VAEs para traducción de imagen a imagen, transferencia de estilo e inpainting
- Generación de Música y Audio:
 - Composiciones musicales originales, efectos de sonido, síntesis de voz
 - RNNs, LSTMs, y transformadores para nuevas melodías, armonías y ritmos
- Descubrimiento de Medicamentos y Ciencia de Materiales:
 - Estructuras moleculares y materiales novedosos con propiedades deseadas
 - Aceleración de los procesos de descubrimiento de medicamentos y diseño de materiales
- Detección de Anomalías y Reconocimiento de Patrones:
 - Modelado de la distribución de datos subyacente para identificar valores atípicos y anomalías
 - Aplicaciones: detección de fraude, seguridad de redes, control de calidad
- Aumento de Datos:
 - Creación de muestras de entrenamiento adicionales donde los datos son escasos o desequilibrados
 - Mejorar el rendimiento del algoritmo de aprendizaje automático
- Simulación de Escenarios y Planificación:
 - Datos sintéticos para simular escenarios, probar hipótesis, evaluar estrategias
 - Aplicaciones: finanzas, logística, planificación urbana, estudios ambientales



Los parámetros de los LLM

- Los Modelos de Lenguaje de Gran Escala (LLM) generan texto coherente y relevante utilizando parámetros específicos.
- Los parámetros clave en la generación de tokens incluyen la temperatura, Top P, Top K, longitud máxima, secuencias de parada, penalización por frecuencia y penalización por presencia.
- La temperatura controla el grado de aleatoriedad en la selección de tokens.
- Top P y Top K restringen el conjunto de tokens considerados para la generación del siguiente token.
- La longitud máxima y las secuencias de parada ayudan a controlar la extensión y estructura de las respuestas generadas.
- Las penalizaciones por frecuencia y presencia reducen la repetición innecesaria de palabras o frases.
- Entender y ajustar estos parámetros permite adaptar el comportamiento del LLM a diferentes aplicaciones.

Siguiente sesión: Introducción a la Ingeniería de Prompts



MUCHAS GRACIAS

Enrique Vasallo

